

Apresentação executiva — Fase 2

Como os dados de alfabetização chegam limpos até o analista

Vinicius Santos · FIAP Pós Tech · Bronze / Silver / Gold na AWS

O problema de dados, não o de modelo

- INEP e Compromisso Criança Alfabetizada publicam metas e taxas por município e por estado — em arquivos separados.
- Sem um lake, cada analista junta as tabelas no notebook e o número muda.
- A Fase 2 entrega uma tabela única: município + ano, já conferida.
- A Fase 3 (modelo) só começa depois desta tabela existir.

Três camadas, dois caminhos

- Bronze: o CSV como veio da Base dos Dados (só o nome da coluna padronizado).
- Silver: rede municipal, chaves IBGE, metas nacional/UF/município e o indicador oficial da UF — uma linha por cidade e ano.
- Gold: três tabelas prontas para o Athena (indicador, meta vs resultado, série).
- Batch lê os CSVs. Streaming (Kinesis) é demonstração: o INEP não publica em tempo real.

Qualidade antes de gravar o Silver

- Cinco checagens: nulo, chave única, taxa entre 0 e 100, UF válida, município existente no diretório IBGE.
- Se alguma falhar, o Silver não é escrito. O relatório JSON/HTML fica como rastro do porquê.
- Isso evita que um join torto vire “dado oficial” na camada analítica.

Dá para testar sem conta AWS

- `python pipelines/orchestrator.py --dry-run`
- O ingest grava Bronze em disco. O Silver lê esse Bronze. O Gold lê o Silver.
- Nenhum bucket é tocado. Os CSVs de origem estão versionados em `raw_downloads/`.
- A Fase 3 consome esse Silver local (colunas traduzidas para português).

Custo: nada ligado o mês inteiro

- S3 + Parquet + Athena (paga o que lê). Sem cluster Spark/Redshift.
- Kinesis só existe durante a demo (minutos), depois o script apaga o stream.
- Pandas cabe na memória: são ~5.500 municípios × dois anos, não bilhões de linhas.

O que entregar para a equipe

- Tabela Silver com município, ano, taxa, metas e indicador oficial da UF.
- Três tabelas Gold no Athena, com partição por ano e estado.
- Código e testes no GitHub: https://github.com/stvinicius/tech_challenge_fase3
- Modelo (Fase 3): não usar esta tabela para colar a taxa do próprio ano.